

Студент : Харов Фарух | Номер студента : 202444907

Классификация бытовых отходов с использованием Transfer Learning

Мини-проект по предмету Deep Learning

Классификация изображений (영상 데이터 분류) · 10 классов

1. Постановка задачи

Проект решает задачу **классификации изображений** — автоматической сортировки бытовых отходов по категориям для системы переработки. Это одна из трёх предложенных тем задания (классификация изображений).

Параметр	Значение
Тип задачи	Многоклассовая классификация изображений
Входная переменная	RGB-изображение, приведённое к размеру 224×224×3 пикселя
Выходная переменная	Один из 10 классов: battery, biological, cardboard, clothes, glass, metal, paper, plastic, shoes, trash
Метрики	Ассурасу (общая точность) и macro F1 (среднее F1 по классам, устойчивое к дисбалансу)

Практическая значимость задачи — автоматизация раздельного сбора мусора, что относится к актуальным экологическим (ESG) направлениям. В качестве основного метода выбран **Transfer Learning** — перенос признаков из модели, предобученной на ImageNet, что является стандартом индустрии при ограниченном объёме данных.

2. Описание данных

Использован сторонний датасет **Garbage Classification V2** (автор Suman Kunwar, Kaggle). Датасет описан в научной статье «The Garbage Dataset (GD): A Multi-Class Image Benchmark for Automated Waste Segregation» (2026), где автор приводит бенчмарк 95.13% accuracy для архитектуры EfficientNetV2S.

Характеристика	Значение
Общее число изображений	12 259
Число классов	10
Формат	JPEG, RGB, размер 256×256 (версия standardized_256)
Разделение train / val / test	70% / 15% / 15%, стратифицированное
train / val / test (примеров)	8593 / 1833 / 1833

Распределение классов и дисбаланс

Датасет существенно несбалансирован: соотношение крупнейшего и наименьшего класса составляет 4.18x (clothes: 1892, trash: 453). Эта особенность напрямую повлияла на выбор методов предобработки (взвешивание классов).

Класс	Кол-во	Доля
clothes	1892	15.4%
glass	1736	14.2%
plastic	1597	13.0%
shoes	1449	11.8%
cardboard	1411	11.5%
paper	1336	10.9%
metal	930	7.6%
battery	756	6.2%
biological	699	5.7%
trash	453	3.7%




Рис. 1. Распределение изображений по классам

Результаты разведочного анализа (EDA)

Визуальный осмотр выборки изображений из каждого класса выявил:

- **Высокая внутриклассовая вариативность.** Классы battery (батарейки разных типов), biological (хлеб, овощи, фрукты, пицца), trash (маски, перчатки, упаковки) и paper (газеты, листы, чеки) визуально очень разнородны.
- **Предсказанные пары путаниц.** На основе визуального сходства заранее предположены три пары, которые модель будет путать: paper ↔ cardboard, glass ↔ metal, plastic ↔ glass. Все три подтвердились на этапе экспериментов.
- **Артефакты.** Часть изображений содержит серые поля-рамки (следствие приведения к 256×256), что обосновало использование случайной обрезки (random crop) как аугментации.

- **Техническая однородность.** Все проверенные изображения подтверждены как 256×256, RGB, JPEG.




Рис. 2. Примеры изображений из каждого класса

3. Предобработка данных

Реализован собственный конвейер обработки данных (`src/data.py`) на базе `tf.data` :

Этап	Описание
Стратифицированное разделение	Каждый класс делится независимо в пропорции 70/15/15, что сохраняет доли классов во всех подвыборках с точностью $<0.1\%$
Аугментация (только train)	Случайная обрезка до 224×224, горизонтальное отражение, изменение яркости и контраста ($\pm 15\%$)
Обработка val / test	Детерминированная центральная обрезка до 224×224 без аугментаций (для воспроизводимости метрик)
Взвешивание классов	Веса по обратной частоте: trash 2.71×, biological 1.75×, battery 1.62×, clothes 0.65×
Оптимизация конвейера	Параллельная загрузка, перемешивание, prefetch для эффективной работы GPU

Стратификация проверена эмпирически: отклонение долей классов между train/val/test не превышает 0.05%, что критично для надёжной оценки на несбалансированном датасете.

4. Оптимизация гиперпараметров и эксперименты

Проведено **пять экспериментов** (при минимальном требовании задания — три). Все эксперименты используют единый конвейер обучения (`src/train.py`) с коллбэками EarlyStopping, ReduceLROnPlateau и ModelCheckpoint, что обеспечивает честное сравнение. Обучение проводилось на Kaggle (GPU P100).

№	Модель / конфигурация	Test Acc	Macro F1	Эпохи	Время
1	Baseline CNN (с нуля, 4 свёрточных блока)	78.61%	0.780	30	5.4 мин
2	ResNet50, замороженная база (frozen)	92.69%	0.920	17	4.5 мин
3	ResNet50, дообучение (fine-tune)	93.29%	0.925	26	7.1 мин
4	EfficientNetV2S, frozen (224px)	92.53%	0.919	20	8.2 мин
5	ResNet50 fine-tune + class weights	93.51%	0.930	28	7.7 мин

Жёлтым выделена лучшая конфигурация.

Эксперимент 1 — Baseline CNN

Простая свёрточная сеть с нуля (4 блока Conv→BatchNorm→ReLU→MaxPool, ~390K параметров). Достигнута точность **78.61%**. Важное наблюдение: train accuracy (77.7%) близка к validation (78.9%), то есть переобучения нет — аугментации работают как эффективный регуляризатор. Слабейший класс — trash (F1 = 0.655), сильнее — clothes (0.880), biological (0.874), battery (0.852). Все три предсказанные в EDA пары путаниц подтвердились.




Рис. 3. Кривые обучения и матрица ошибок Baseline CNN

Эксперимент 2 — ResNet50 (замороженная база)

Применён Transfer Learning: ResNet50 с весами ImageNet используется как извлекатель признаков (заморожен), обучается только классификатор (20K из 23.6M параметров). Результат — **92.69%**, прирост **+14.08 п.п.** относительно baseline. Уже на первой эпохе validation accuracy достигла 89.7%, что выше финального результата baseline. Все классы улучшились; наибольший прирост у ранее слабых: metal (+0.24 recall), trash (+0.23), shoes (+0.22).




Рис. 4. Кривые обучения и матрица ошибок ResNet50 frozen

Эксперимент 3 — ResNet50 (дообучение)

Двухфазное обучение: фаза 1 — обучение классификатора (заморожённая база), фаза 2 — разморозка последнего блока ResNet50 (conv5_block3) с пониженным в 100 раз learning rate ($1e-5$). Слои BatchNorm оставались замороженными для сохранения статистик ImageNet. Результат — **93.29%**. Главное достижение: путаница plastic→glass снижена с 8% до 5% (относительное улучшение 38%), что подтверждает гипотезу о пользе дообучения для визуально близких классов.




Рис. 5. Кривые обучения (две фазы) и матрица ошибок ResNet50 fine-tuned

Эксперимент 4 — EfficientNetV2S

Сравнение альтернативной, более современной архитектуры. Результат — **92.53%**, что немного ниже ResNet50. Это методологически важный вывод: EfficientNetV2S спроектирована для входа 384×384 (принцип compound scaling), а мы использовали 224×224 для честного сравнения с ResNet50. Это объясняет как отставание от ResNet50, так и разрыв в 2.6 п.п. от бенчмарка статьи (95.13% на 384×384). При этом EfficientNetV2S показала наименьшее переобучение (разрыв train-val всего ~1.5%).





Рис. 6. Кривые обучения и матрица ошибок EfficientNetV2S

Эксперимент 5 — ResNet50 fine-tune + взвешивание классов (лучшая модель)

К лучшей модели (эксперимент 3) добавлены веса классов по обратной частоте. Результат — **93.51%**, лучший в проекте. Уникальность: улучшились *одновременно* и общая точность, и маско F1 — взвешивание классов обычно жертвует общей точностью, но здесь умеренные веса дали выигрыш по всем направлениям.

Ключевое достижение — пробит «потолок» класса trash. В экспериментах 2-4 recall класса trash застрял на уровне 0.81 независимо от архитектуры. Взвешивание подняло его до **0.881** (+7.5 п.п.). Это подтвердило диагноз из EDA: ограничивающим фактором для trash был дисбаланс данных, а не качество признаков или архитектура.

Класс trash	Без весов	С весами	Δ
recall	0.806	0.881	+0.075
precision	0.806	0.787	−0.019
F1	0.806	0.831	+0.025






Рис. 7. Кривые обучения и матрица ошибок лучшей модели

5. Итоги

Финальные гиперпараметры (лучшая модель)

Гиперпараметр	Значение
Архитектура	ResNet50 (ImageNet) + GlobalAveragePooling + Dropout(0.3) + Dense(10)
Стратегия обучения	Двухфазная: классификатор → дообучение последнего блока
Optimizer	Adam
Learning rate	1e-3 (фаза 1) → 1e-5 (фаза 2), с ReduceLROnPlateau
Batch size	32
Функция потерь	Sparse Categorical Crossentropy (from logits)
Регуляризация	Аугментация, Dropout, EarlyStopping
Взвешивание классов	Обратная частота (trash 2.71× ... clothes 0.65×)
Размер входа	224×224×3

Итоговая производительность

Метрика	Значение
Test accuracy	93.51%
Test macro F1	0.930
Лучший класс (clothes, F1)	0.989
Худший класс (trash, F1)	0.831
Прирост над baseline	+14.90 п.п.
Отставание от бенчмарка статьи (95.13%, 384px)	−1.62 п.п.

Выводы

- **Transfer Learning** дал решающий вклад — переход от обучения с нуля (78.6%) к ResNet50 (92.7%) добавил более 14 п.п. за счёт переноса семантических признаков ImageNet.
- **Дообучение и взвешивание классов** довели результат до 93.5% и решили проблему редкого класса trash, диагностированную ещё на этапе EDA.
- **Архитектура не отделима от разрешения входа** — EfficientNetV2S не превзошла ResNet50 при 224px, что согласуется с теорией compound scaling.
- **Подтверждена ценность EDA** — предсказанные на основе визуального анализа пары путаниц (paper/cardboard, glass/metal, plastic/glass) подтвердились на матрицах ошибок, а диагноз проблемы trash (дисбаланс, а не признаки) подтверждён серией экспериментов.

Возможные направления развития

- Использование версии датасета 384×384 с EfficientNetV2S для приближения к бенчмарку 95.13%.
- Проверка обобщающей способности на независимом датасете (например, TrashNet) — тест Out-of-Distribution.

Код и воспроизводимость. Весь код организован в виде переиспользуемых модулей (src/data.py , model.py , train.py , utils.py) и ноутбуков экспериментов.

GitHub: <https://github.com/wayofell/trash-classification>